E3 | DOS FORMAS DE CONSTRUIR EL AGENTE

Atención técnica para Tostadero Retiro S.L. | Sesión 3: bucle, trazas y aprobación humana

CASO COMÚN

El Restaurante Lumbre informa de que su cafetera de dos grupos no calienta y pregunta por un pedido pendiente. El agente identifica al cliente, consulta el pedido, propone registrar una incidencia de prioridad alta y espera aprobación antes de escribir en la base de datos.

IMPLEMENTACIÓN

Agente propio. Usa directamente la API Messages de Claude. El bucle está en Python: decide si responder o llamar a una herramienta, ejecuta la función y devuelve el resultado al modelo. El límite de ocho pasos, los errores, el formato de mensajes y las trazas quedan visibles y se pueden ajustar. La terminal pide aprobación antes de crear la incidencia.

LangChain. `create_agent` resuelve el ciclo de herramientas. `HumanInTheLoopMiddleware` pausa la escritura, y `InMemorySaver` conserva el estado para reanudar el grafo tras la decisión. `ModelCallLimitMiddleware` limita las llamadas al modelo a ocho. Se muestran trazas de las llamadas y sus resultados.

COMPARACIÓN

Aspecto	Agente propio	LangChain
Tamaño del código base publicado	94 líneas; 80 de código	59 líneas; 47 de código
Bucle y mensajes	Control directo, explícito y ajustable	Resueltos por el framework; menos infraestructura
Límite y trazas	8 pasos; imprime herramienta y salida	8 llamadas al modelo; imprime llamadas y resultados
Aprobación humana	Pregunta manual antes de ejecutar	Interrupción del grafo y reanudación
Cambio de proveedor	Requiere adaptar cliente y formato	Puede bastar con cambiar la cadena del modelo compatible

CONCLUSIÓN

Para aprender, depurar y controlar cada mensaje, conviene el agente propio: se ve el bucle completo y resulta fácil modificarlo. Para extender el prototipo con menos código, cambiar de proveedor y gestionar una pausa humana, LangChain aporta más estructura. Su coste es que parte del comportamiento queda dentro del framework y hay que comprender el grafo. Aquí el checkpointer es en memoria: se puede reanudar mientras el proceso siga abierto, pero no recupera la aprobación tras reiniciarlo.

Nota: recuento de líneas del código base publicado por el profesor; la versión de LangChain entregada añade la impresión de trazas.